

# جلسه بیستم آمار و احتمال صمدی دکتر شرفی زارچی دانشگاه شریف

در جلسه قبل متوجه هدف علم آماری شدیم که در تلاقی با از جزو به کل ببریم. حالا ما دنبال پارامترهای مثل  $\mu$  و  $\sigma^2$  در کل جامعه هستیم. دست به دامن تخمین زدن می بینیم. این جلسه کلاً به روشی برای پیدا کردن  $\mu$  و  $\sigma^2$  می پردازیم.

## پارامترهای توزیع (تخمین)

به دنبال پیدا کردن  $\mu$  و  $\sigma^2$  در کل جامعه هستیم نه حالتی که توزیع داده ما روی دو نیم (توزیع در حدس زدم دیا از روشی برای ریله بدست آوردیم و باز به داده های sample به دنبال تخمین پارامترهای توزیع در کل جامعه هستیم.)

تخمین نقطه ای: پارامتر را نزدیک رابطه مثل میانگین یا واریانس یا ... از داده های sample بدست می آوریم.

تخمین بازه ای: چون تخمین نقطه ای رو نزدیک بازه مثلا  $\pm 1$  گزارش می کنیم و می گیم با احتمال مثلا 95 درصد، پارامتر ما در این بازه است. هدف ما پیدا کردن کوچکترین بازه با بیشترین احتمال است.

پارامتر  $\theta$  از جمعیت که می رویم یک داده ای sample داریم با پارامتر  $\theta$  و می خواهیم با تخمین های نقطه ای یک تخمین از  $\theta$  برای  $\theta$  ارائه بدهیم.

$$x_1, \dots, x_{10}$$

$$\hat{\mu}_1 = x_1$$

$$\hat{\mu}_2 = \bar{x} = \frac{x_1 + x_2 + \dots + x_{10}}{10}$$

$$E(\hat{\mu}_1) = \mu$$


$$E(\hat{\mu}_2) = \mu$$

کدام یک از  $\hat{\mu}_1$  بهتر است  $\hat{\mu}_2$  بهتر است؟

$\hat{\mu}_2$  چون واریانسش کمتره


## صغیرهای ارزیابی تخمین های نقطه ای

Var دست Var کمتر باشه بهتر.



Var: صغیرهای برای تخمین ما داریم که وقت آن ما با هم مقایسه می کنیم. یکی از این صغیرها هر دو دایره یک مقدار، بری گردونی اما منبره بهتره چس Var کمتری داره

Bias: اندازگی روبرو استفاده می کنیم و آنرا  $Bias(\hat{\theta}) = E(\hat{\theta}) - \theta$  یعنی  $E(\hat{\theta}) = \theta$  اون موقع تخمینر رو نااریب یا (Unbiased Estimator) می نامیم.  $Bias(\hat{\theta}) = E(\hat{\theta} - \theta) = E(\hat{\theta}) - \theta$  که ما به دنبال پیدا کردن این صغیر ما هستیم.



با توجه به این ها ویرانه ریسک تخمیری هستیم نه بایاس کم و واریانس کمی داشته باشیم.

Mean Squared Error : متوسط مربع خطا. نه مالتین لرنینگ به نسبت کاربرد داره و از رابطی بویه روبرو به دست می آید.

$$E((\hat{\theta} - \theta)^2)$$

$$\begin{aligned} \text{Var}(X) &= E(X^2) - E(X)^2 \rightarrow \text{Var}(\hat{\theta} - \theta) = E((\hat{\theta} - \theta)^2) - E(\hat{\theta} - \theta)^2 \\ &= \text{Var}(\hat{\theta}) - \text{MSE}(\hat{\theta}) - \text{Bias}^2(\hat{\theta}) \end{aligned}$$

بر رابطی طلایی 3 تا معیار ارزیابی داریم

$$\text{MSE} = \text{Var}(\hat{\theta}) + \text{Bias}(\hat{\theta})^2$$

مثال  $\hat{\mu}_1 = X_1, \hat{\mu}_2 = \bar{X}, \text{ sample} = X_1, X_2, \dots, X_{10}$

از دیدگاه Bias با هم تقابلی ندارند.  
از دیدگاه Var :

$$\text{Var}(\hat{\mu}_1) = \sigma^2$$

$$\text{Var}(\hat{\mu}_2) = \frac{\sigma^2}{n} \rightarrow \text{بسته چو واریانس کمتری داره}$$

$$\text{MSE}(\hat{\mu}_1) = \sigma^2 - 0 = \sigma^2$$

$$\text{MSE}(\hat{\mu}_2) = \frac{\sigma^2}{n} - 0 = \frac{\sigma^2}{n}$$

پس با توجه به برابر بودن Bias و واریانس کمتر MSE کمتر برای  $\hat{\mu}_2$  ،  $\hat{\mu}_2$  تخمیر بهتری هست.

آیای توان Estimator دارد که  $Var=0$  باشد اما Bias داشته باشد؟ آره مثلا  $\hat{\mu}_3$  چون عدد ثابت واریانس ندارد و  $Bias=19-\mu$

## معیار سازگاری (Consistency)

آره  $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_n$  یک دنباله از تخمینها باشند

$$\forall \epsilon > 0 \quad \lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| \geq \epsilon) = 0$$

یعنی به حالتی که تعداد تخمینها زیاد باشد و فاصله از مقدار اصلی  $\theta$  به سمت 0 بره اون موقع اون دنباله از تخمینها رو سازگاری میگویند.

$$\hat{\theta}_1 = x, \quad \hat{\theta}_2 = \frac{x_1 + x_2}{2}, \quad \dots, \quad \hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{مثلا}$$

این فقط تقریبی هست و در دنیای واقعی ما میایم بی نهایت تا تبدیل بگیریم بلکه روی کاغذ ثابت می کنیم روشی تبدیل گیری ما و تخمینها حالتی که به هم میل کنه اون موقع سازگار هست.

مثال تخمین  $\hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n x_i$  را بررسی کنیم.

$$E(\hat{\theta}_n - \mu) = \frac{1}{n} = B(\hat{\theta}_n) \Rightarrow \text{Unbiased}$$

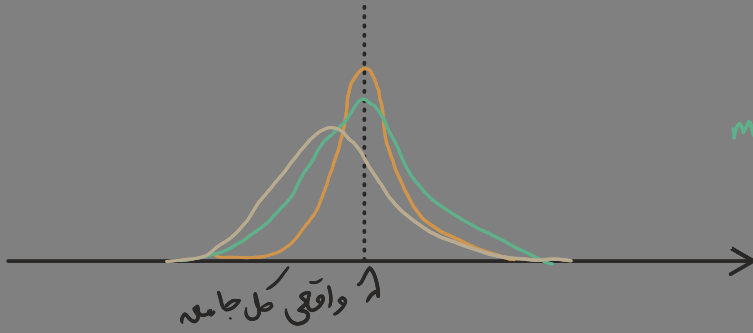
سازگار هست.  $\Rightarrow$  طبق قانون اعداد بزرگ به سمت 0 میل میکنه به سمت صفر  $\text{if } n \rightarrow \infty \text{ then } \frac{1}{n} \rightarrow 0$

تخیمتری داریم که unbiased باشد در عین حال سازگار هم نباشه.

$$\hat{\theta}_1 = x_1, \quad \hat{\theta}_2 = x_1, \quad \dots, \quad \hat{\theta}_n = x_1 \quad \text{or} \quad \hat{\theta}_n = x_n$$

بایاس ندارد و سازگار هم نیست

## مقایسه‌ی چند تخمینر



هم بایاس دارم و هم واریانس زیادی دارم  
واریانسش یکم زیاده اما بایاس نیست  
واریانسش خیلی کم ر بایاس هم نیست

برای  $Var$ ،  $Unbiased$  و استایل  $Unbiased$  اینجی هست؟

چون  $\sum_{i=1}^n x_i = n\bar{x}$

$$\bar{s}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \frac{1}{n} \sum_{i=1}^n \bar{x}^2 - \frac{2}{n} \sum_{i=1}^n x_i \bar{x}$$

$$E(\bar{s}^2) = Var(\bar{x}) + E(\bar{x})^2 = \frac{\sigma^2}{n} + \mu^2$$

$\underbrace{\sigma^2}_{Var(x_i)} + \underbrace{\mu^2}_{E(x_i)}$

$(Var(x) = E(x^2) - E(x)^2)$

$$E(\bar{s}^2) = \frac{1}{n} \sum_{i=1}^n E(x_i^2) - \frac{1}{n} \sum_{i=1}^n E(\bar{x}^2) = \frac{1}{n} \sum_{i=1}^n E(x_i^2) - \frac{\sigma^2}{n} - \mu^2$$

$$= \frac{1}{n}(\sigma^2 + \mu^2) - \frac{\sigma^2}{n} - \mu^2 = \sigma^2 \left( \frac{n-1}{n} \right)$$

چون برابرش نیست پس  $Unbiased$  نیست

برای  $Unbiased$  کردن  $\frac{n}{n-1}$  ضرب کنیم که درست کار کنه

$$\hat{\sigma}^2 = \frac{n}{n-1} \bar{s}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

الان این دیکه نااریب هست ( $Unbiased$ )

این سه معیارهای تخمینر خوب بود اگر دم. حالا اصلاً خطوری یک تخمینر بسازیم؟ روشی ساختن تخمینر!

تخمینر بیشینه درست نمایی (Maximum Likelihood Estimator) کاربردش کین به یادگیری ماشین

یک  $sample$  داریم که از توزیع خاصی (مثلاً  $Poisson$ ) می‌خوایم یک  $\theta$  بدست بیاریم که احتمال دین داده‌های  $sample$  با این  $\theta$  بیشینه شه.

$$P(x_1, x_2, \dots, x_n; \theta) \sim \text{Max}$$

فرض کنیم مثلاً  $\theta$  رو داریم یا بدست آوردیم. با این وضعیت طبعاً  $sample$  روی  $\theta$  با این بانه و قطعاً احتمال اینکه  $\theta$  برابر با  $\theta$  باشه واقعا بیشتره پس  $\theta = \theta$  نوکتر استی می‌دیم.

نکته هم برای توزیع های گسسته و هم برای توزیع های پیوسته کار میکنه

$$\left\{ \begin{array}{l} L(\theta|x) = PMF_{\theta}(x) \quad \text{Discrete} \quad \text{Likelihood} \\ L(\theta|x) = PDF_{\theta}(x) \quad \text{Continuous} \end{array} \right.$$